

Classificação de Câncer de Pele

Projeto Final de Machine Learning



Professor: Fabio Ayres

Alunos: Caio Aranha, Pedro Paulo Camargo e Thomas Chabro

1. Introdução e Definição do Problema

O câncer de pele é o tipo mais comum da doença no Brasil, representando 30% de todos os tumores malignos registrados no país. Felizmente, possui uma alta taxa de sobrevivência (superior a 90%), o que muito se deve ao diagnóstico precoce. A distinção visual entre todos os possíveis tipos de lesões benignas e malignas é sutil, o que acaba por exigir anos de experiência e estudo por parte dos profissionais. Neste contexto, o uso de Machine Learning aplicada ao problema aparece como uma ferramenta poderosa para escalar e democratizar bons diagnósticos.

Desta forma, o projeto tem como objetivo desenvolver diferentes modelos de classificação de imagem de lesões de pele, fazendo então um estudo comparativo entre seus desempenhos e técnicas utilizadas. Iremos investigar como arquiteturas e abordagens diferentes se comportam frente ao desafio. Especificamente, iremos trabalhar em cima de 3 cenários principais:

- CNN (Rede Neural Convolutacional) Simples (com variações no pipeline)
- A combinação da CNN inicial com um Visual Transformer (ViT) construído do zero
- A combinação da CNN inicial com aplicação de Transfer-Learning com Fine Tuning, utilizando um Visual Transformer pré-treinado

Para a construção e treinamento destes modelos, foi escolhido o dataset [Skin Cancer: MNIST HAM10000](#) (caso o link não esteja disponível, ele também estará presente nas referências deste paper, assim como no projeto entregue pelo github). Este conjunto de dados possui 10015 imagens diferentes, cada uma associada a uma das **7 categorias distintas de lesões**. São elas:

- | | |
|--------------------------|---------|
| 1. Nevos melanocíticos | (nv) |
| 2. Melanoma | (mel) |
| 3. Queratose benigna | (bkl) |
| 4. Carcinoma basocelular | (bcc) |
| 5. Queratose actínica | (akiec) |
| 6. Lesões vasculares | (vasc) |
| 7. Dermatofibroma | (df) |

Por questão de praticidade, em diversas imagens do relatório, cada uma dessas classes será referenciada por seu acrônimo, indicado entre parênteses na lista acima.

2. Análise Exploratória

Como primeiro passo do projeto, iremos então fazer uma análise exploratória do dataset mencionado, para entender melhor possíveis limitações e ajustes necessários. Esta é uma etapa crucial, pois ter um conjunto de dados sólido é essencial para a confiabilidade e desempenho do modelo.

O dataset HAM10000 contém sete tipos de lesões cutâneas pigmentadas, sendo as classes acima mencionadas. Cada uma das 10015 amostras possui:


- uma imagem dermatoscópica (aproximadamente 600x450 px)
- um conjunto de metadados relacionados ao paciente da amostra (idade, sexo, localização da lesão, etc.)

A primeira preocupação é a quantidade de dados faltantes. Para isso, obtivemos a seguinte tabela:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10015 entries, 0 to 10014
Data columns (total 7 columns):
#   Column      Non-Null Count  Dtype
---  -
0   lesion_id   10015 non-null  object
1   image_id    10015 non-null  object
2   dx          10015 non-null  object
3   dx_type     10015 non-null  object
4   age         9958 non-null   float64
5   sex         10015 non-null  object
6   localization 10015 non-null  object
dtypes: float64(1), object(6)
memory usage: 547.8+ KB
```

Em termos de integridade dos dados, é possível notar que os metadados estão bem completos. A única coluna com dados faltantes é a de “age” (idade). Mesmo assim, a parcela de dados faltantes é ínfima (menos de 1%). Além disso, pela proposta do projeto se tratar de classificação de câncer de pele a partir da imagem, não precisamos nos preocupar com os metadados.

Assim, seguimos então para melhor entender a distribuição das classes. Para isso, plotamos o seguinte histograma:




Como podemos ver, aqui está um grande problema da nossa base de dados. O dataset é **fortemente desbalanceado**, com a classe NV (Nevos Melanocíticos) concentrando **mais da metade das imagens**. Em números absolutos, enquanto a classe NV possui mais de 6700 imagens, classes como vasc (Lesões Vasculares) e df (Dermatofibrose) não possuem nem 150 imagens no dataset.


Este cenário exige atenção redobrada, pois cria uma armadilha do ponto de vista estatístico. Isso pois o modelo tende a convergir para um viés majoritário. No treinamento, ele acaba aprendendo que classificar tudo como a classe predominante, irá acertar na maioria das vezes, dado o desbalanceamento, criando assim uma acurácia alta, porém artificial. O modelo irá obter bom desempenho (acurácia) não por aprender corretamente as features, e sim por chutar a mais frequente.

Indo ainda mais além, é importante entender o impacto clínico, pensando realmente no caso de uso do modelo para detecção de doenças. As doenças de alto risco, como o Melanoma (mel) e o Carcinoma (bcc), fazem parte das classes minoritárias, enquanto a majoritária é uma lesão benigna. Assim, ignorando o desbalanceamento, teríamos um problema não só em termos de desempenho absoluto do modelo (acurácia), mas principalmente em relação à sensibilidade do modelo (recall), que seria baixa para doenças graves. Em outras palavras, o modelo apresentaria um maior número de Falsos Negativos, que é justamente o contrário do que buscamos para esses casos. Em medicina, deixar de detectar uma doença maligna e grave é significativamente mais grave do que alarmar falsamente um paciente saudável.

Por conta desses fatores, técnicas de balanceamento serão imprescindíveis para a construção do modelo em questão, e serão abordadas mais à frente durante o desenvolvimento.

Seguindo na análise exploratória, serão então apresentados alguns exemplos de amostras de cada classe de lesão.





A partir destas imagens, já é possível observar alguns padrões aparentes. Os mais nítidos são:

- **Lesões vasculares (vasc)** tendem a apresentar coloração mais avermelhada e áreas bem delimitadas;
- **Melanomas (mel)** costumam ser mais escuros, com bordas irregulares e variação de tonalidade dentro da mesma lesão;
- **Dermatofibromas (df)** frequentemente exibem uma região central mais claras ou esbranquiçadas

3. Metodologia e Desenvolvimento (Arquiteturas)


Nesta seção, iremos explorar mais a fundo a escolha de cada uma das nossas frentes, assim como a maneira como construímos cada uma delas. Porém, antes disso, será apresentado rapidamente o setup do projeto. Foi optado pelo grupo a construção de um arquivo Jupyter Notebook, documento organizado em células e que permite a

combinação de códigos executáveis com áreas de texto, sendo assim perfeito para o desenvolvimento de um projeto com discussões, textos, imagens e códigos juntos. Além disso, foram utilizadas bibliotecas vistas durante o curso, como **tensorflow** e **scikit-learn (sklearn)** para o desenvolvimento e treinamento dos modelos.

3.1 O que é uma CNN?

Agora, passando para a metodologia de fato, vamos entender melhor a primeira escolha e ponto de partida das frentes do projeto: a Rede Neural Convolucional (CNN, do inglês, Convolutional Neural Network). Este modelo é o padrão de ouro clássico para processamento de imagens. Diferentemente das redes neurais convencionais, as CNN são projetadas para lidar com inputs de grade (como imagens), e não como um vetor plano de dados. O funcionamento gira em torno da operação de **convolução**.

Este processo consiste na aplicação de um filtro que vai deslizando sobre os dados de input, realizando multiplicações por elemento, produzindo como resultado o que chamamos de “**feature map**”. Ou seja, permite com que redes neurais detectem padrões nas imagens, como bordas, texturas, formatos, etc.



A imagem acima resume muito bem o funcionamento da camada de convolução, onde o filtro é aplicado, fazendo multiplicações nos dados de input, para então entender um conjunto de pixels como um valor só (uma feature).

Por sua capacidade técnica e sua vasta aplicação na área de classificação de imagens, optamos por seguir com a CNN como ponto de partida do projeto. A partir da construção de uma CNN simples, iremos a cada iteração trazer ferramentas e técnicas complementares para então ter um panorama geral e por fim um estudo comparativo dessas ferramentas no problema em questão.

É importante ressaltar ainda, que neste caso, que a CNN não é a nossa linha de base. Isto pois já é esperado, da CNN, um desempenho razoável. O que é necessário,

antes disso, é estabelecer um “pisso” de performance. E justamente para isso, desenvolvemos o modelo Dummy.

3.2 Modelo Dummy

Este tipo de arquitetura, de maneira sucinta, não “aprende” nada. O que ele faz são predições baseadas em regras simples (estratégias escolhidas), sem nenhum entendimento sobre as features dos dados de entrada. Para o nosso caso, escolhemos a estratégia “most_frequent”, que como o nome diz, faz com que o modelo simplesmente chute sempre a classe majoritária (no nosso caso, a “nv”).

```
Treinamento e Avaliação do Dummy

# Modelo dummy que sempre prediz a classe majoritária
dummy_model = DummyClassifier(strategy='most_frequent', random_state=SEED)
dummy_model.fit(x_train, y_train)

print("Modelo dummy treinado!")

[47]
...  Modelo dummy treinado!
```


Este comportamento do modelo Dummy (de chutar a classe mais frequente), é o mais adequado para o caso, dado que evidencia o desbalanceamento do modelo. Se uma única classe é muito comum, o modelo Dummy terá uma acurácia razoável, mas será péssimo para as outras classes (quando analisamos separadamente o desempenho do modelo para cada).

```
# Predições
y_pred_val = dummy_model.predict(X_val)
y_pred_test = dummy_model.predict(X_test)

# Acurácias
print_accuracy_summary("Dummy Classifier", y_val, y_pred_val, y_test, y_pred_test)

=====
Dummy Classifier:
=====
Acurácia Validação: 66.93%
Acurácia Teste:      66.93%
```

Como podemos ver, o modelo teve um desempenho de 66.93% no dataset de teste, o que é um valor razoável, considerando que é um Dummy. Porém, também como discutido, quando vemos o desempenho separado para cada classe, notamos que a acurácia total na verdade mascara a qualidade do modelo.



Como podemos ver, o modelo chutou “vasc” (Lesões vasculares) para todas as amostras.

RELATÓRIO DE CLASSIFICAÇÃO - DUMMY CLASSIFIER:				
	precision	recall	f1-score	support
Nevos melanocíticos	0.0000	0.0000	0.0000	49
Melanoma	0.0000	0.0000	0.0000	77
Queratose benigna	0.0000	0.0000	0.0000	165
Carcinoma basocelular	0.0000	0.0000	0.0000	17
Queratose actínica	0.0000	0.0000	0.0000	167
Lesões vasculares	0.6693	1.0000	0.8019	1006
Dermatofibroma	0.0000	0.0000	0.0000	22
accuracy			0.6693	1503
macro avg	0.0956	0.1429	0.1146	1503
weighted avg	0.4480	0.6693	0.5367	1503

Com os valores numéricos separados por classe, podemos notar como a acurácia de ~67% é enganosa, e que não pode ser utilizada como único indicador para o desempenho do modelo.

Com nossa linha de base desenvolvida, podemos então seguir para o desenvolvimento da nossa CNN de fato.

3.3 CNN Simples

Como explicado anteriormente, a CNN é um tipo de rede neural projetada para trabalhar com **dados em grade**, como imagens. No caso do problema em questão, cada imagem é representada como um tensor (altura, largura e canais).

Os principais blocos de uma CNN são:

1. Camadas Convolucionais (**Conv2d**)
 - Aplicam filtros (kernels) que “varrem” a imagem
 - Cada filtro aprende a detectar padrões locais
 - A saída são **mapas de ativação** que destacam regiões onde esses padrões foram encontrados
 2. Função de ativação (**ReLU**)
 - Introduz não-linearidade, permitindo que a rede aprenda relações mais complexas
 - Mantém valores apenas positivos, o que ajuda na estabilidade do treino
 - Evita “vanishing-gradient” (quando gradientes vão se tornando extremamente baixos)
- $$\text{ReLU}(z) = \begin{cases} 0, & \text{if } z < 0 \\ z, & \text{if } z \geq 0 \end{cases}$$
3. Camadas de pooling (**MaxPooling2D**)
 - Reduzem a resolução espacial dos mapas de ativação
 4. Dropout
 - Zera aleatoriamente uma fração das ativações durante o treino
 - Ajuda a evitar **overfitting**, fazendo a rede depender menos de neurônios específicos
 5. Flatten + camadas densas (**Dense**)
 - Depois de várias convoluções/pooling, os mapas de ativação são “achatados” em um vetor 1D (**Flatten**)
 - Esse vetor é passado por camadas densas que funcionam como um classificador tradicional
 - A última camada usa **softmax** para produzir uma **distribuição de probabilidades** sobre o número de classes de lesões do dataset

Como primeiro modelo, vamos optar por uma arquitetura padrão e simples, sem técnicas explícitas de balanceamento (do dataset). O objetivo desta primeira versão é de verificar quanto de desempenho já ganhamos em relação ao modelo Dummy, apenas por utilizar a estrutura espacial das imagens.

A arquitetura utilizada foi de 2 blocos:

- Bloco 1: 2 convoluções (32 filtros) + Max Pooling + Dropout (0.25)
- Bloco 2: 2 convoluções (64 filtros) + Max Pooling + Dropout (0.4)
- Cabeça Densa: Flatten + Dense (128) + Dropout (0.5) + Dense (7, softmax)

O número de 7 na última camada se deve ao número de classes diferentes existentes no dataset.

```
def build_simple_cnn(input_shape, num_classes):
    model = Sequential()

    # --- Input layer ---
    model.add(Input(shape=input_shape))

    # Bloco 1
    model.add(Conv2D(32, kernel_size=(3, 3),
                     activation='relu', padding='same'))
    model.add(Conv2D(32, kernel_size=(3, 3),
                     activation='relu', padding='same'))
    model.add(MaxPooling2D(pool_size=(2, 2)))
    model.add(Dropout(0.25))

    # Bloco 2
    model.add(Conv2D(64, (3, 3), activation='relu', padding='same'))
    model.add(Conv2D(64, (3, 3), activation='relu', padding='same'))
    model.add(MaxPooling2D(pool_size=(2, 2)))
    model.add(Dropout(0.40))

    # Cabeça densa
    model.add(Flatten())
    model.add(Dense(128, activation='relu'))
    model.add(Dropout(0.5))
    model.add(Dense(num_classes, activation='softmax'))

    return model
```

O trecho de código acima representa a criação da CNN, de maneira modular (foi criada uma função de construção do modelo, dado que vamos utilizar várias vezes, para as várias iterações). Esta arquitetura gerou um total de **8.455.207 parâmetros**, sendo todos treináveis.


Além disso, para compilar o modelo, utilizamos uma learning rate de 0.0005, assim como um função de erro (“loss”) do tipo “categorical_crossentropy”.

```
# 2. Compilação
optimizer = Adam(learning_rate=0.0005)

model_cnn_simple.compile(
    optimizer=optimizer,
    loss='categorical_crossentropy',
    metrics=['accuracy'],
)
```

O problema em questão não se trata de um problema binário, e sim de uma classificação de 7 classes mutuamente exclusivas (cada imagem indica apenas um tipo de doença). Desta forma, precisamos de uma função de cálculo de erro multiclasse. Para isso, a função escolhida trabalha juntamente com a função de ativação softmax na última camada. Ela acaba por penalizar o modelo com base na distância entre a distribuição de probabilidade predita e a classe real (representada via One-Hot Encoding). Assim, quanto mais o modelo estiver “confiante” na classe errada, mais ele será penalizado, forçando então a rede a ajustar os pesos na direção correta.


Após treinado, estes foram os resultados obtidos pelo modelo:



A rede apresenta um aprendizado consistente no conjunto de treino: a acurácia cresce de forma contínua até cerca de 87%, enquanto o loss cai progressivamente. No entanto, após poucas épocas, observa-se uma estagnação clara no conjunto de validação. Alguns pontos importantes:

- A acurácia de validação estabiliza entre 73% e 75%, sem acompanhar o crescimento observado no treino.
- O loss de validação diminui nas primeiras épocas, mas logo passa a oscilar e volta a crescer após aproximadamente a 8ª época.

Todos estes fatores, conjuntamente, indicam que o modelo está sofrendo de **overfitting**. Assim, é necessária uma análise mais aprofundada nos resultados do modelo para o conjunto de teste.



RELATÓRIO DE CLASSIFICAÇÃO - CNN SIMPLES:				
	precision	recall	f1-score	support
Nevos melanocíticos	0.5556	0.1020	0.1724	49
Melanoma	0.5410	0.4286	0.4783	77
Queratose benigna	0.3687	0.4424	0.4022	165
Carcinoma basocelular	0.0000	0.0000	0.0000	17
Queratose actínica	0.4133	0.1856	0.2562	167
Lesões vasculares	0.8178	0.9324	0.8713	1006
Dermatofibroma	0.6154	0.3636	0.4571	22
accuracy			0.7239	1503
macro avg	0.4731	0.3507	0.3768	1503
weighted avg	0.6886	0.7239	0.6926	1503

A partir destas imagens, é possível analisar métricas:

1. Globais

A acurácia de **72.4%** mostra uma melhora em relação ao modelo Dummy, o que indica que a CNN está de fato aprendendo padrões visuais que sejam úteis ao problema. Além disso, analisa-se:

- Média Simples entre as classes (**macro avg**) tanto para o recall e F1 (média harmônica entre o recall e a precisão do modelo). Ambos os valores flutuam ao redor de 36%, mostrando um **desempenho global baixo** quando olhamos todas as classes de maneira igual.
- Média ponderada pelo número de exemplos (**weighted avg**), também tanto para recall quanto F1, onde ambos também são próximos, ao redor de 70%. Como a base é altamente desbalanceada, o modelo parece ter bom desempenho, pois acerta muitas vezes a classe que é majoritária (como também vemos na matriz de confusão).

2. Por classe

Classe	support	precision	recall	f1-score	Comentário
Nevos melanocíticos	49	0.56	0.10	0.17	A rede identifica poucos casos reais; recall muito baixo.
Melanoma	77	0.54	0.43	0.48	Acerta um pouco menos da metade dos melanomas; desempenho moderado.
Queratose benigna	165	0.37	0.44	0.40	Resultados medianos
Carcinoma basocelular	17	0.00	0.00	0.00	Não detecta nenhum caso real; desempenho equivalente ao dummy.
Queratose actínica	167	0.41	0.18	0.25	A maior parte das queratoses actínicas é classificada como outras classes.
Lesões vasculares	1006	0.82	0.93	0.87	Classe dominante; desempenho muito alto devido ao desbalanceamento.
Dermatofibroma	22	0.62	0.36	0.46	Quando previsto é geralmente correto, porém muitos casos reais passam despercebidos.

Com isso, é possível concluir que a rede ficou realmente boa para classificar Lesões Vasculares (a classe dominante). Entretanto, nas classes minoritárias (com menos amostras), o recall encontrado é baixo, ainda que alguns melhoraram em relação ao baseline.

Portanto, a CNN simples **supera o baseline Dummy**, e aprende padrões visuais relevantes. Porém, fica nítido que é **fortemente enviesada** para a classe majoritária, apresentando desempenho abaixo do desejado para classes minoritárias. Como discutido anteriormente, este comportamento é indesejado, dado que para o contexto do problema, falsos negativos são **críticos**. O modelo está generalizando pouco e ainda não é adequado para uso em cenários reais.

A partir disso então, partimos para nossa primeira iteração, implementando pesos de classes para tentar combater o desbalanceamento do dataset.

3.4 CNN com Pesos de Classes

Com o intuito de mitigar o problema do desbalanceamento do dataset, a arquitetura irá agora implementar, juntamente com a CNN, **pesos de classes**. Este método acrescenta um peso (um número) à cada classe, relativo à distribuição da classe no dataset, de forma que classes mais raras (minoritárias - com menos amostras) terão pesos maiores, enquanto que classes majoritárias (com maior número de amostras), terão pesos menores. Este número será aplicado ao erro calculado, com o intuito de que erros em classes raras sejam mais graves que erros em classes comuns. Assim, a loss passa a penalizar mais os erros em classes minoritárias, incentivando o modelo a prestar atenção nelas.

Estes pesos são calculados automaticamente por um método da biblioteca `scikit-learn`, com a estratégia “balanced”. A fórmula básica é:

$$w_c = \frac{N}{n_c \cdot K}$$

Onde:


- **N** é o número de amostras
- **K** é o número de classes
- **N_c** é o número de amostras da classe (c)
- **W_c** é o peso atribuído a classe (c)

Aplicando ao nosso dataset, obtivemos os valores:

Pesos das classes:

```
Classe 0 (nv    ): peso = 4.37 ( 229 imagens)
Classe 1 (mel   ): peso = 2.78 ( 360 imagens)
Classe 2 (bkl   ): peso = 1.30 ( 769 imagens)
Classe 3 (bcc   ): peso = 12.52 (  80 imagens)
Classe 4 (akiec ): peso = 1.29 ( 779 imagens)
Classe 5 (vasc  ): peso = 0.21 (4693 imagens)
Classe 6 (df    ): peso = 10.11 (  99 imagens)
```


Uma vez construído o modelo, agora considerando os pesos atribuídos a cada classe, obtivemos os seguintes resultados durante o treinamento:



É notável que o uso de pesos faz alterar o comportamento do modelo. A **rede aprende de forma consistente no conjunto de treino** e também melhora de maneira razoável no conjunto de validação, mas em um ritmo mais lento. Ainda, nota-se que:

- A acurácia de treino sobe até cerca de 74%, mas de maneira mais lenta, o que já era esperado já que o modelo agora sofre penalizações maiores quando erra classes raras.
- A validação se estabiliza ao redor de 65%, mantendo um gap ainda considerável entre as curvas.
- O erro de treino cai continuamente, enquanto o erro de validação **diminui nas primeiras epochs e depois oscila ao redor do mesmo valor**.

De modo geral, o modelo aprende, mas a discrepância entre treino e validação persiste. Contudo, o comportamento das curvas indica que o modelo foi forçado a se ajustar a classes antes negligenciadas, o que é refletido nos resultados por classe. Uma vez aplicado o modelo ao conjunto de teste, temos os resultados:



RELATÓRIO DE CLASSIFICAÇÃO - CNN COM PESOS DE CLASSE:

	precision	recall	f1-score	support
Nevos melanocíticos	0.3600	0.1837	0.2432	49
Melanoma	0.4105	0.5065	0.4535	77
Queratose benigna	0.3351	0.3758	0.3543	165
Carcinoma basocelular	0.1556	0.4118	0.2258	17
Queratose actínica	0.2899	0.4790	0.3612	167
Lesões vasculares	0.8703	0.7207	0.7885	1006
Dermatofibroma	0.2955	0.5909	0.3939	22
accuracy			0.6221	1503
macro avg	0.3881	0.4669	0.4029	1503
weighted avg	0.6904	0.6221	0.6463	1503

Novamente, é essencial analisar métricas separadamente:

1. Métricas globais

A acurácia de **62,2%** se mostra menor do que a CNN simples (~72%), mas isso já era esperado, dado que estamos forçando o modelo a se preocupar mais com classes raras. Em relação a outros dados, tem-se que:

- Média Simples entre as classes (**macro avg**) tanto para o recall e F1 (média harmônica entre o recall e a precisão do modelo). Ambos os valores flutuam ao redor de 44%, mostrando um desempenho ainda **médio**, mas com melhor equilíbrio entre as classes do que a CNN simples.
- Média ponderada pelo número de exemplos (**weighted avg**), também tanto para recall quanto F1, onde ambos também são próximos, ao redor de 63%. Os resultados são piores do que a CNN simples, pois a performance da classe majoritária caiu, trazendo a média para baixo.

Em suma, o modelo com peso de classes **sacrifica a acurácia global** e o desempenho da classe majoritária em prol de tentar **equilibrar melhor as classes minoritárias**.

2. Métricas por classe

Classe	support	precision	recall	f1-score	Comentário
Nevos melanocíticos	49	0.36	0.18	0.24	Leve melhora em comparação ao dummy, mas ainda baixo.
Melanoma	77	0.41	0.50	0.45	Recall superior ao modelo simples; sensibilidade aumentou.
Queratose benigna	165	0.33	0.38	0.35	Comportamento semelhante ao modelo anterior.
Carcinoma basocelular	17	0.16	0.41	0.23	Grande avanço: saiu de recall 0% para 41,18%.
Queratose actínica	167	0.29	0.48	0.36	Outro caso em que o recall aumentou substancialmente.
Lesões vasculares	1006	0.87	0.72	0.79	Caiu em recall (antes >90%), como esperado ao reduzir o peso dessa classe.
Dermatofibroma	22	0.30	0.59	0.39	Recall aumentou muito; a rede agora identifica mais casos verdadeiros.

Em resumo, a CNN com pesos de classe **não é melhor em termos de acurácia global**, mas cumpre o objetivo principal dos class-weights: ela **equilibra melhor o desempenho entre classes**, aumentando o recall de várias classes minoritárias (incluindo casos mais críticos, como o melanoma e o carcinoma), ao custo de reduzir o desempenho da classe majoritária.

Portanto, considerando o contexto do problema em questão, onde falsos negativos podem ser mais graves que erros nas classes mais comuns, esse trade-off acaba por ser interessante, favorecendo esta arquitetura contra a CNN simples. Ainda assim, não resolve o problema de generalização, sendo necessário buscar outras alternativas.

3.5 CNN com Oversampling

Nesta iteração, iremos testar uma abordagem alternativa ao desbalanceamento do modelo: o **oversampling** de classes minoritárias.


A ideia é de aumentar artificialmente o número de amostras das classes com poucos exemplos, replicando amostras (com reposição) até que todas as classes tenham

aproximadamente a mesma quantidade de imagens. Assim, o modelo vê um conjunto de treino balanceado, sem precisar utilizar os pesos de classe.

Assim, diferentemente dos class-weights (que atuam no treinamento), esta abordagem atua diretamente nos **dados**, criando um novo dataset balanceado. A função loss então permanecerá a mesma que a inicial da CNN simples, mas o gradiente então passa a ser influenciado por um número mais justo de exemplos de cada classe.


Uma vez aplicado o oversampling no conjunto de dados, agora no conjunto de treino, todas as classes possuem a mesma quantidade de exemplos do que a classe majoritária (4.693 imagens).

Treinando então nossa CNN para este novo conjunto de dados, temos:



A partir disso, é possível notar que a CNN treinada com oversampling apresenta um comportamento característico desse tipo de técnica. A accuracy de treino sobe rapidamente e atinge quase 95%, enquanto a loss cai para valores próximos de zero: um sinal claro de memorização, esperado quando muitas imagens são replicadas no conjunto de treino. Já no conjunto de validação, a accuracy melhora nas primeiras épocas, chegando a cerca de **72%**, mas em ritmo muito inferior à de treino.

Por outro lado, a loss de validação aumenta ao longo das épocas, mesmo com a accuracy praticamente estável. À primeira vista isso parece overfitting, mas na verdade é um efeito comum quando se usa oversampling. Como o modelo vê muitas cópias idênticas das classes minoritárias no treino, ele aprende a reconhecer esses padrões com facilidade, mas também passa a produzir probabilidades menos confiantes quando recebe imagens que não foram replicadas.



RELATÓRIO DE CLASSIFICAÇÃO - CNN COM OVERSAMPLING:					
	precision	recall	f1-score	support	
Nevos melanocíticos	0.3684	0.4286	0.3962	49	
Melanoma	0.3675	0.5584	0.4433	77	
Queratose benigna	0.3064	0.4364	0.3600	165	
Carcinoma basocelular	0.0909	0.1176	0.1026	17	
Queratose actínica	0.2797	0.5210	0.3640	167	
Lesões vasculares	0.9221	0.6829	0.7847	1006	
Dermatofibroma	0.5625	0.4091	0.4737	22	
accuracy			0.6128	1503	
macro avg	0.4139	0.4506	0.4178	1503	
weighted avg	0.7220	0.6128	0.6489	1503	

Voltando então aos dados:

1. Métricas Globais

A acurácia de **61,3%** é próxima ao modelo com pesos de classes (~62%) e bem inferior ao Dummy (~67%).

- Média simples entre classes (**macro avg**): tanto para o recall e F1 (média harmônica entre o recall e a precisão do modelo). Ambos os valores flutuam ao redor de 43, indicando um leve ganho de equilíbrio entre as classes.
- Ponderado pelo número de exemplos (**weighted avg**): , também tanto para recall quanto F1, onde ambos também são próximos, ao redor de 63%. Os valores são muito próximos aos da CNN com pesos.

Em síntese: apesar da queda na acurácia geral, o oversampling melhora a sensibilidade de algumas classes sub-representadas, mas falha em estabilizar o desempenho e mantém forte dificuldade de generalização.

2. Métricas por classe

Classe	support	precision	recall	f1-score	Comentário
Nevos melanocíticos	49	0.36	0.43	0.40	Sensivelmente melhor que com pesos; recall mais alto.
Melanoma	77	0.37	0.56	0.44	Recall elevado, superando tanto a CNN simples quanto o modelo com pesos.
Queratose benigna	165	0.30	0.44	0.36	Melhor recall, precisão baixa; resultado mediano.
Carcinoma basocelular	17	0.09	0.12	0.10	Desempenho fraco; oversampling não resolveu esta classe.
Queratose actínica	167	0.28	0.52	0.36	Aumento significativo no recall; um dos melhores ganhos do oversampling.
Lesões vasculares	1006	0.92	0.68	0.78	Recall reduzido em relação à CNN simples, como era esperado.
Dermatofibroma	22	0.56	0.41	0.47	Desempenho razoável, F1 maior que no modelo com pesos.

Portanto, a CNN com oversampling apresenta desempenho similar ao modelo com pesos de classe em termos de recall macro, mas não supera nenhuma abordagem em acurácia geral. O oversampling melhora a detecção das classes minoritárias, indicando que a estratégia contribui para reduzir o viés do modelo, mas ao replicar imagens gera forte overfitting e instabilidade no conjunto de validação.

Em comparação com o modelo com pesos de classe, o oversampling mostra alguns ganhos específicos (como recall mais alto em melanoma e queratose actínica), mas perde em estabilidade e qualidade global do modelo. As curvas reforçam que o oversampling simples não é suficiente para lidar com o desbalanceamento sem prejudicar a generalização.

3.6 CNN com Oversampling e Data Augmentation

Nesta iteração, serão utilizadas a combinação de estratégias para lidar com o desbalanceamento e a escassez de dados em algumas classes. Esta iteração se aproxima muito do passo anterior, porém ao invés de simplesmente duplicar imagens para os casos minoritários, são geradas novas imagens com leves distorções, como de rotação, brilho, etc.



Esta técnica aumenta a diversidade das amostras sem coletar novas imagens, ajudando a reduzir overfittin, tornando o modelo mais robusto. Combinando as duas

estratégias, nós equilibramos a **quantidade** de exemplos por classe (oversampling) e aumentamos a **variedade** de exemplos dentro de cada classe (augmentation).

O oversampling é aplicado **somente no conjunto de treino**, enquanto a validação e o teste continuam usando os dados originais, preservando a distribuição real do problema. Para implementar o Data Augmentation, utilizamos o método ImageDataGenerator

```
train_datagen_over = ImageDataGenerator(  
    rotation_range=25,  
    width_shift_range=0.1,  
    height_shift_range=0.1,  
    zoom_range=0.2,  
    horizontal_flip=True,  
    fill_mode='nearest'  
)  
  
# Gerador para o treino oversampled + augmentado  
train_generator_over = train_datagen_over.flow(  
    X_train_over,  
    y_train_over_encoded,  
    batch_size=BATCH_SIZE,  
    shuffle=True  
)
```

Uma vez treinado, o modelo obteve:




A rede **aprende de forma mais irregular no conjunto de treino**, devido às transformações aleatórias aplicadas em cada batch, mas ainda assim apresenta uma tendência de melhora. No conjunto de validação, o aprendizado ocorre de maneira **mais estável e gradual**.

Observando o gráfico:

- A accuracy de treino oscila bastante e chega a valores acima de **80–90%** em algumas épocas, mas essa instabilidade é típica da data augmentation, que dificulta o treino.
- Já a accuracy de validação se mantém bem mais consistente, estabilizando ao redor de 65%, com pequenas variações ao longo das épocas. Não acompanha os picos do treinamento, o que evidencia que o modelo está sendo forçado a generalizar.
- A loss de treino cai rapidamente, embora apresente oscilações grandes - novamente um efeito esperado devido às imagens transformadas a cada iteração.
- A loss de validação **reduz nas primeiras épocas, mas permanece praticamente estável**, sem subir de forma significativa, indicando que **o overfitting foi reduzido** em relação ao oversampling puro.

O padrão indica que o data augmentation cumpre seu papel de reduzir overfitting: mesmo com oversampling, o modelo não memoriza cópias estáticas das imagens. Ainda assim, a convergência é mais lenta e ruidosa devido à alta variação no conjunto de treino. Ao vermos os resultados no dataset de teste:



RELATÓRIO DE CLASSIFICAÇÃO - CNN COM OVERSAMPLING + DATA AUGMENTATION:				
	precision	recall	f1-score	support
Nevos melanocíticos	0.3737	0.7551	0.5000	49
Melanoma	0.5070	0.4675	0.4865	77
Queratose benigna	0.3955	0.5273	0.4519	165
Carcinoma basocelular	0.2667	0.7059	0.3871	17
Queratose actínica	0.3023	0.6407	0.4107	167
Lesões vasculares	0.9508	0.6531	0.7743	1006
Dermatofibroma	0.7391	0.7727	0.7556	22
accuracy			0.6341	1503
macro avg	0.5050	0.6460	0.5380	1503
weighted avg	0.7654	0.6341	0.6702	1503

1. Métricas Globais

A acurácia de 63.4% é ligeiramente menor relação ao oversampling puro (~61%).

- Média simples entre classes (**macro avg**) apresentou um recall médio de ~64%, enquanto que o F1 score fica ao redor de 54%. Ou seja, o modelo ficou **significativamente mais equilibrado entre classes**, mesmo com acurácia global menor.
- Ponderado pelo número de exemplos (**weighted avg**) apresenta retorno mais equilibrado, sem depender apenas da classe majoritária.

Em resumo, **perdeu acurácia global**, mas **ganhou muito recall médio**, especialmente nas classes minoritárias. O modelo ficou menos “viciado” em lesões vasculares.

2. Métricas por classe

Classe	support	precision	recall	f1-score	Comentário
Nevos melanocíticos	49	0.37	0.76	0.50	Grande avanço em recall; mais da metade dos casos agora são identificados.
Melanoma	77	0.51	0.47	0.49	Desempenho Médio.
Queratose benigna	165	0.40	0.53	0.45	Sensível melhora em recall; desempenho superior ao oversampling simples.
Carcinoma basocelular	17	0.27	0.71	0.39	Um dos maiores ganhos: recall muito superior às abordagens anteriores.
Queratose actínica	167	0.30	0.64	0.41	Notável aumento em recall; antes variava entre 18% e 52%.
Lesões vasculares	1006	0.95	0.65	0.77	A classe majoritária perdeu recall, mas mantém boa precisão e F1.
Dermatofibroma	22	0.74	0.77	0.76	Melhor desempenho até aqui; excelente recall e F1 elevados.

Os resultados deixam claro que o modelo está muito mais equilibrado. A maioria das classes apresenta recall acima de 50%, caso inédito até este ponto das experimentações. As classes mais difíceis (carcinoma basocelular e queratose actínica) demonstram avanços expressivos.

Portanto, o uso de oversampling combinado com data augmentation variável em cada época se mostrou o método mais eficaz até o momento para lidar com o desbalanceamento. Embora a acurácia global permaneça inferior ao baseline dummy, o desempenho por classe, especialmente recall macro, melhora substancialmente.

Diferente do oversampling simples, que gerava overfitting severo, a variação contínua das imagens impede a memorização e força a rede a aprender padrões mais gerais. Isso se reflete em ganhos marcantes em classes minoritárias. Entre todas as abordagens testadas até agora, **esta é a que apresenta o melhor equilíbrio entre as classes e os maiores avanços em recall macro**.

3.7 CNN com Metadados (e outras features)


Até então, as CNNs construídas estavam considerando apenas as imagens de pele como entrada. Porém, como explicado nas sessões iniciais, o dataset HAM10000 também traz informações tabulares, associadas a cada uma das imagens, e trazendo mais informações sobre o paciente em questão, carregando contexto clínico importante (como

idade, sexo, localização da lesão), dado que alguns tipos de lesões são mais comuns em certas faixas etárias ou regiões do corpo.

Assim, nesta iteração, será construída uma rede multimodal, que recebe uma imagem (processada por uma CNN) e um vetor de metadados (processado por camadas densas). O modelo processa ambos os tipos de dados para realizar a classificação final, procurando reduzir ambiguidades entre lesões visualmente parecidas.

Para isso, reutilizamos a mesma CNN usada nas seções anteriores - juntamente com o **oversampling** e **data augmentation**. Em paralelo, um pequeno MLP processa o vetor de metadados. As duas representações são concatenadas e passam por camadas densas adicionais, resultando na camada softmax final.


Uma vez treinado, o modelo apresenta:



A rede apresenta melhor capacidade preditiva e aprende de forma mais consistente no conjunto de treino, já que os metadados fornecem informações adicionais que facilitam a separação entre classes. No conjunto de validação, o aprendizado ocorre de maneira mais suave e progressiva, com pouca oscilação. Observando o gráfico:

- **A acurácia de treino cresce de forma contínua**, chegando a valores próximos de **90%**, sem oscilações abruptas.
- **A acurácia de validação acompanha o progresso do treino**, mas de forma mais suave, estabilizando perto de **75%**, indicando boa generalização.
- **A loss de treino diminui constantemente**, atingindo valores bastante baixos, o que confirma que o modelo consegue capturar bem a estrutura combinada de imagem + informações tabulares.
- **A loss de validação, apesar de apresentar oscilações típicas de data augmentation, mantém-se estável sem tendência de crescimento, sugerindo controle de overfitting.**

Além disso, analisando os resultados no dataset de teste:



RELATÓRIO DE CLASSIFICAÇÃO - CNN COM IMAGENS + METADADOS + OVERSAMPLE + DATA AUG:

	precision	recall	f1-score	support
Nevos melanocíticos	0.3980	0.7959	0.5306	49
Melanoma	0.4393	0.6104	0.5109	77
Queratose benigna	0.4975	0.6061	0.5464	165
Carcinoma basocelular	0.3750	0.7059	0.4898	17
Queratose actínica	0.3672	0.5629	0.4444	167
Lesões vasculares	0.9528	0.7425	0.8346	1006
Dermatofibroma	0.6400	0.7273	0.6809	22
accuracy			0.7019	1503
macro avg	0.5242	0.6787	0.5768	1503
weighted avg	0.7822	0.7019	0.7270	1503

1. Métricas Globais

A acurácia de ~70% e apresenta melhor equilíbrio entre as classes.

- Média simples entre classes (**macro avg**) com valores de 0.68 para recall e 0.58 para F1. Esses valores representam o **melhor recall** entre todas as abordagens até então.
- Ponderado pelo número de exemplos (**weighted avg**) com recall e F1 ao redor de 72%. São valores elevados, o que indica que o modelo funciona bem no conjunto de dados como um todo, mas continua sofrendo com classes menos frequentes.

Conclusão parcial: o modelo sacrifica um pouco de acurácia bruta, mas **ganha muito em equilíbrio entre classes**, especialmente para aquelas minoritárias.

2. Métricas por classe

Classe	support	precision	recall	f1-score	Comentário
Nevos melanocíticos	49	0.40	0.80	0.53	Forte avanço; recupera muitos casos reais.
Melanoma	77	0.44	0.61	0.51	Desempenho Médio.
Queratose benigna	165	0.50	0.61	0.55	Sensível melhora em todas as métricas.
Carcinoma basocelular	17	0.38	0.71	0.49	Um dos maiores ganhos: recall muito superior aos modelos sem técnicas de balanceamento.
Queratose actínica	167	0.37	0.56	0.44	Bom avanço em recall; resultado equilibrado.
Lesões vasculares	1006	0.95	0.74	0.83	Recall menor por perda de dominância, mas excelente precisão e F1 muito alto.
Dermatofibroma	22	0.64	0.73	0.68	Desempenho Bom

Essas métricas mostram que o modelo com oversampling, data augmentation e metadados é o mais equilibrado até agora. Quase todas as classes atingem recall superior a 50%, incluindo classes críticas e antes extremamente problemáticas, como carcinoma basocelular e nevos melanocíticos.

Portanto, concluímos que a CNN com imagens, metadados, oversampling e data augmentation é, até este ponto, o modelo **mais equilibrado no desempenho entre as classes**. Embora a acurácia geral seja menor que o modelo com metadados sem balanceamento, o ganho em recall nas classes minoritárias é substancial, e esse é o ponto central em um problema clínico, onde perder casos críticos é inaceitável. A combinação das três estratégias mostra-se eficaz:

- **Metadados** fornecem contexto adicional e ajudam a separar classes difíceis.
- **Oversampling** aumenta a representatividade das classes minoritárias.
- **Data augmentation** impede o overfitting gerado pelas duplicações do oversampling.

O resultado é um modelo que detecta muito melhor classes raras, mantém desempenho forte na classe majoritária e apresenta as melhores métricas macro até agora.

3.8 Vision Transformer (ViT)

Para a última etapa de modelagem do projeto, optamos por explorar uma arquitetura que representa o atual estado da arte em diversas tarefas de Visão Computacional, mas

que opera sob um paradigma completamente diferente das CNNs: os **Vision Transformers (ViT)**.

Diferentemente das Redes Convolucionais, que processam a imagem através de filtros locais (focando em bordas e texturas vizinhas), o ViT trata a imagem como uma **sequência de pedaços (patches)**.

A intuição por trás dessa abordagem é:

1. Dividir a imagem em pequenos quadrados (patches);
2. Transformar esses quadrados em vetores lineares;
3. Utilizar o mecanismo de **Self-Attention** (Atenção) para que o modelo aprenda a relacionar qualquer parte da imagem com qualquer outra parte, independentemente da distância física entre elas.

No contexto deste projeto, implementamos uma versão adaptada, que chamaremos de **"ViT-Mini"**, treinada do zero (*from scratch*). A arquitetura foi construída com as seguintes camadas principais:

- **Patch Encoder:** Responsável por "cortar" a imagem e adicionar informações de posição (para que a rede saiba onde cada pedaço estava);
- **Transformer Block:** Camadas de Multi-Head Attention e Normalização;
- **MLP Head:** Classificador final denso.

```
class PatchEncoder(layers.Layer):
    def __init__(self, num_patches, projection_dim, **kwargs):
        super().__init__(**kwargs)
        self.num_patches = num_patches
        self.projection_dim = projection_dim

        # Projeção linear de cada patch para o espaço de embedding
        self.projection = layers.Dense(projection_dim)

        # Embedding de posição [0 .. num_patches-1]
        self.position_embedding = layers.Embedding(...)

    def call(self, patches):
        # Vetor [0, 1, 2, ..., num_patches-1]
        positions = tf.range(start=0, limit=self.num_patches, delta=1)


        # Projeção dos patches + embedding de posição
        encoded = self.projection(patches) + self.position_embedding(positions)
        return encoded

    def get_config(self): ...
```

Esta abordagem é ambiciosa para o dataset HAM10000. Sabe-se na literatura que os Transformers possuem pouco "viés indutivo" (não assumem que pixels vizinhos são

correlacionados, como as CNNs fazem). Por isso, geralmente exigem volumes massivos de dados para generalizar bem. O objetivo aqui foi testar os limites dessa arquitetura em um dataset de médio porte (~10 mil imagens).

Após o treinamento, obtivemos as seguintes curvas de aprendizado:




O ViT-Mini apresenta um comportamento distinto das CNNs. Mesmo treinado do zero, ele converge rapidamente e mantém estabilidade razoável no conjunto de validação.

Principais observações:

- A acurácia de treino cresce continuamente, chegando a aproximadamente **94%**.
- A acurácia de **validação** estabiliza **entre 68% e 72%**, sem quedas bruscas, mas também sem acompanhar integralmente o treino.
- O loss de treino cai de forma consistente até valores **muito baixos** (≈ 0.15).
- O loss de validação, no entanto, não acompanha a redução do treino e permanece **estável** na faixa **0.85–1.0**, oscilando ao longo das épocas.

Além disso, analisando os resultados no dataset de teste:



RELATÓRIO DE CLASSIFICAÇÃO - VISION TRANSFORMER MINI (FROM SCRATCH):

	precision	recall	f1-score	support
Nevos melanocíticos	0.3690	0.6327	0.4662	49
Melanoma	0.5048	0.6883	0.5824	77
Queratose benigna	0.5061	0.5030	0.5046	165
Carcinoma basocelular	0.2500	0.4118	0.3111	17
Queratose actínica	0.3123	0.6527	0.4225	167
Lesões vasculares	0.9489	0.7018	0.8069	1006
Dermatofibroma	0.6897	0.9091	0.7843	22
accuracy			0.6713	1503
macro avg	0.5115	0.6428	0.5540	1503
weighted avg	0.7762	0.6713	0.7024	1503

1. Métricas Globais

- A acurácia final de **67,13%** posiciona o ViT-Mini acima das estratégias de balanceamento simples (Oversampling com ~61% e Pesos de Classe com ~62%), porém ainda inferior à arquitetura Multimodal completa (70,19%).
- Média Simples (Macro avg):** Apresentou um *recall* de **0,64** e F1 de **0,55**. Este é um ponto de destaque: o mecanismo de atenção do ViT garantiu um dos **melhores recalls macro** entre todos os modelos testados, indicando forte capacidade de generalização entre classes distintas.
- Média Ponderada (Weighted avg):** Com recall de 0,67 e F1 de 0,70, os valores demonstram um equilíbrio geral sólido, não dependendo exclusivamente da classe majoritária para sustentar as métricas.

2. Métricas Por Classe

Classe	support	precision	recall	f1-score	Comentário
Nevos melanocíticos	49	0.37	0.63	0.47	Detecta mais da metade dos casos.
Melanoma	77	0.50	0.69	0.58	Bom Recall
Queratose benigna	165	0.51	0.50	0.50	Desempenho médio
Carcinoma basocelular	17	0.25	0.41	0.31	Desempenho Médio/Baixo
Queratose actínica	167	0.31	0.65	0.42	Um dos maiores recalls para esta classe; ViT capta bem suas variações.
Lesões vasculares	1006	0.95	0.70	0.81	A precisão permanece alta, mas o recall cai devido ao foco maior em classes minoritárias.
Dermatofibroma	22	0.69	0.91	0.78	Bom desempenho; melhor recall para essa classe até agora.

Ao analisarmos o desempenho específico para cada tipo de lesão, notamos comportamentos promissores:

- **Dermatofibroma (df):** Obteve um resultado excelente com **91% de recall**, sendo o melhor desempenho para esta classe em todo o projeto.
- **Melanoma (mel):** Apresentou um bom recall de **0,69**, confirmando que o modelo consegue focar em características relevantes de lesões malignas.
- **Queratose actínica (akiec):** Com recall de **0,65**, o ViT superou a maioria das CNNs nesta classe, captando bem suas variações visuais.
- **Lesões vasculares (vasc):** A precisão permaneceu altíssima (**0,95**), mas o recall caiu para 0,70, uma consequência natural do modelo distribuir sua "atenção" para as classes minoritárias.
- **Carcinoma basocelular (bcc):** Ainda se mostrou um desafio, com desempenho médio/baixo (0,41 de recall).
- **Nevos e Queratose benigna:** Mantiveram desempenhos medianos, detectando cerca de metade a 60% dos casos.

Em suma, o ViT-Mini demonstra uma **forte capacidade de generalização interclasse** e sensibilidade para padrões difíceis (como visto em *akiec* e *df*), beneficiando-se claramente do mecanismo de *Self-Attention*. Embora careça de mais dados ou regularização extra para atingir a acurácia global da abordagem Multimodal, ele representa um avanço promissor e competitivo, provando ser capaz de detectar classes minoritárias com eficiência.

4. Conclusão e Considerações Finais

O projeto teve como objetivo principal o desenvolvimento e a análise comparativa de diferentes arquiteturas de *Machine Learning* para a classificação de lesões de pele, utilizando o dataset HAM10000. Ao longo do estudo, partimos de uma linha de base estatística até arquiteturas multimodais e modernas, como os Vision Transformers (ViT). A análise dos resultados nos permite extrair inferências cruciais tanto do ponto de vista técnico quanto da aplicabilidade clínica:

4.1. A Ilusão da Acurácia Global

Um dos aprendizados mais importantes deste estudo foi a constatação de que, em datasets desbalanceados, a acurácia global é uma métrica insuficiente e potencialmente perigosa.

- O **Modelo Dummy** atingiu uma acurácia de aproximadamente **67%** apenas prevendo a classe majoritária (*nevos melanocíticos*).
- Modelos subsequentes, embora apresentassem acurácias globais numericamente próximas (entre 70% e 75%), trouxeram um ganho substancial na capacidade de generalização. Isso evidenciou que o sucesso do modelo não reside em acertar o

que é comum, mas sim em **equilibrar o desempenho** para não negligenciar classes raras e críticas.

4.2. A Importância do Contexto Clínico (Abordagem Multimodal)

A iteração que combinou o processamento de imagens (via CNN) com dados tabulares (idade, sexo e localização da lesão) apresentou os resultados mais consistentes do projeto. Esta abordagem **Multimodal (CNN + Metadados)** demonstrou que, assim como na dermatologia clínica, o diagnóstico é favorecido pelo contexto do paciente. A adição dessas features permitiu à rede reduzir ambiguidades visuais, resultando no **melhor Recall Macro** entre todas as abordagens testadas.

4.3. Vision Transformers (ViT) vs. CNNs

A exploração do **ViT-Mini** trouxe um contraponto arquitetural interessante. Embora seja o estado da arte em diversas tarefas de visão computacional, no contexto deste projeto, ele enfrentou a limitação do tamanho do dataset (apenas ~10 mil imagens).

- As **CNNs** possuem um viés indutivo (foco em padrões locais) que favorece o aprendizado com menos dados.
- Os **Transformers**, por sua vez, exigem volumes massivos de dados para criar generalizações robustas. Para superar as CNNs neste cenário específico, a estratégia ideal para trabalhos futuros seria a aplicação de **Transfer Learning**, utilizando modelos pré-treinados em grandes bases (como ImageNet) para contornar a escassez de dados nativos.

4.4. Veredito Final e Impacto Clínico

Considerando o cenário médico, onde o custo de um **Falso Negativo** (não detectar um câncer existente) é incomensuravelmente maior do que um Falso Positivo, a métrica de **Sensibilidade (Recall)** torna-se prioritária.

Desta forma, a arquitetura recomendada como a mais robusta dentre as desenvolvidas é a **CNN Multimodal com Oversampling e Data Augmentation**.

Apesar de sacrificar pontualmente a precisão na classe majoritária, este modelo oferece o equilíbrio mais seguro, garantindo taxas de detecção superiores para lesões malignas como o Melanoma e o Carcinoma. O estudo conclui, portanto, que a inserção de metadados clínicos e o balanceamento artificial são etapas indispensáveis para aproximar modelos acadêmicos de uma ferramenta real de auxílio diagnóstico.

Fontes

<https://www.gov.br/saude/pt-br/assuntos/saude-com-ciencia/noticias/2025/fevereiro/cancer-d-e-pele-representa-30-de-todos-os-tumores-malignos-registrados-no-pais>

<https://www.ibm.com/think/topics/convolutional-neural-networks> (imagem conv layer)